Taller 3 IA

Punto 1: Probabilidades y utilidad esperada

A.

$P(I, A) = P(I)P(A|I)$

$P(I = 1) = 0{,}10$

$P(A = 1|I = 1) = 0{,}9$

$P(A = 1|I = 0) = 0{,}05$

Incendio	Alarma	Cálculo	P(I,A)
0	0	(0.9)(0.95)	0,855
0	1	(0.9)(0.05)	0,045
1	0	(0.1)(0.1)	0,010
1	1	(0.9)(0.1)	0,090
		Suma	**1**

$P(A = 1) = P(I = 0, A = 1) \ + \ P(I = 1, A = 1) = 0{,}045 + 0{,}090 \ = 0{,}135$

$$P(I = 1|A = 1) = \frac{P(A = 1|I = 1) * P(I = 1)}{P(A = 1)} = \frac{0{,}090}{0{,}135} \ = \ 0{,}6667$$

D.

Caso	P(I=1|e)	EU monitorear	EU inspeccionar	EU brigada	Acción
sin_evidencia	0,100	-10,000	-9,700	-27,500	inspeccionar
alarma	0,667	-66,667	-19,333	-13,333	brigada
sin_alarma	0,012	-1,156	-8,197	-29,711	monitorear

Punto 2: Inferencia exacta por enumeración

B.

Caso Bosque	Evidencia	P(I=1|e)
sin_evidencia	-	0,0652
alarma	A=1	0,3295
alarma_falla	A=1, F=1	0,0768
humo_calor (extra)	H=1 T=1	0,8792

rara (extra)	T=1, F=1, A=1	0,2608

C.

$$P(H|I,S) = \frac{P(S)P(I|S)P(H|I)}{\sum_H P(S)\,P(I|S)P(h|I)} = P(H|I)$$

Consulta	Resultado
P(H=1|I=1,S=0)	0,8000
P(H=1|I=1,S=1)	0,8000
P(H=1|S=0)	0,1140
P(H=1|S=1)	0,3100
P(H=1)	0,1924

Ambas condicionales valen 0.8 = P(=1|I=1). Sin observar Incendio el camino Sequedad → Incendio →Humo queda activo: la sequedad cambia la probabilidad de incendio (0.02 vs 0.30) y esta cambia la de humo. Por eso P(H=1|S=0)=0.114 ≠ P(H=1|S=1)=0.31: Humo y Sequedad son marginalmente dependientes.

Punto 3: Eliminación de variables e inferencia aproximada

3a. Eliminación de variables en cadena_humo

Se calcula P(Humo=1) en la red *cadena_humo*, eliminando primero Sequedad y después Incendio. La estructura es Sequedad → Incendio → Humo; por lo tanto, la probabilidad conjunta se escribe como:

P(S,I,H) = P(S) × P(I|S) × P(H|I)

Factores iniciales

Se toman las probabilidades de las tablas condicionales del escenario. Para cada valor 0 se utiliza el complemento de la probabilidad de 1.

Factor P(S):

Sequedad	P(S)
0	0.6000
1	0.4000

Factor P(I|S):

Sequedad	Incendio	P(I|S)
0	0	0.9800
0	1	0.0200
1	0	0.7000
1	1	0.3000

Factor P(H|I):

Incendio	Humo	P(H|I)
0	0	0.9000
0	1	0.1000
1	0	0.2000
1	1	0.8000

Primera eliminación: Sequedad

Se multiplican los factores P(S) y P(I|S), obteniendo f(S,I) = P(S) × P(I|S).

S	I	Operación	f(S,I)
0	0	0.60 × 0.98	0.5880
0	1	0.60 × 0.02	0.0120
1	0	0.40 × 0.70	0.2800
1	1	0.40 × 0.30	0.1200

Se suma sobre Sequedad:

f(I=0) = 0.5880 + 0.2800 = 0.8680

f(I=1) = 0.0120 + 0.1200 = 0.1320

Incendio	f(I)
0	0.8680
1	0.1320

Segunda eliminación: Incendio

Se multiplica el factor anterior por P(H|I): g(I,H) = f(I) × P(H|I).

I	H	Operación	g(I,H)
0	0	0.868 × 0.90	0.7812
0	1	0.868 × 0.10	0.0868
1	0	0.132 × 0.20	0.0264
1	1	0.132 × 0.80	0.1056

Después se suma sobre Incendio:

P(H=0) = 0.7812 + 0.0264 = 0.8076

P(H=1) = 0.0868 + 0.1056 = 0.1924

Humo	Probabilidad
0	0.8076
1	0.1924

Comprobación: 0.8076 + 0.1924 = 1. Por tanto, **P(Humo=1) = 0.1924**. El resultado coincide con eliminación de variables en el programa usando orden topológico. El mayor factor producto de esta ejecución tiene 4 filas.

3b. Comparación de los órdenes de eliminación

Se consulta Incendio con Alarma=1 en la red *bosque*. Por enumeración se obtuvo P(Incendio=1|Alarma=1) = 0.329517. Después se ejecutó eliminación con los órdenes topológico e inverso.

Orden topológico: Tormenta, Sequedad, Falla, Humo y Temperatura. El mayor factor producto tuvo 8 filas.

Orden inverso: Temperatura, Humo, Falla, Sequedad y Tormenta. El mayor factor producto tuvo 32 filas.

Método	P(Incendio=1|Alarma=1)	Mayor factor producto
Enumeración	0.329517	—
Eliminación topológica	0.329517	8 filas
Eliminación inversa	0.329517	32 filas

Los pesos previos a la normalización fueron:

I=0: 0.12131955648 ; I=1: 0.05962399020

P(I=1|A=1) = 0.05962399020 / (0.12131955648 + 0.05962399020) = 0.329517

Los tres métodos coinciden porque calculan la misma probabilidad, pero las sumas y multiplicaciones se agrupan en distinto orden. El mayor factor del orden inverso es cuatro veces el del topológico (32 frente a 8 filas), por lo que puede requerir más memoria y operaciones.

3c. Implementación del muestreo a priori

Se implementó *prior_sample* en *algorithms/sampling.py*. La función recorre las variables en orden topológico y consulta P(X=1|padres) usando los valores ya asignados. Para cada variable genera un número con *rng.random()*: si es menor que la probabilidad, asigna 1; en caso contrario, 0. Devuelve un diccionario con la muestra completa, sin fijar evidencia.

3d. Implementación del muestreo por rechazo

Se implementó *sampling_ask* usando *prior_sample*. Sin rechazo y sin evidencia, cuenta las muestras generadas para estimar una marginal. Cuando se activa el rechazo, descarta los mundos incompatibles con toda la evidencia y normaliza solo los conteos aceptados. El parámetro *samples* indica intentos totales, no muestras aceptadas. Si no se acepta ninguna, devuelve (None, 0), sin concluir que la evidencia sea imposible.

3e. Comparación del muestreo a priori y por rechazo

Se realizaron seis experimentos en la red *bosque*, consultando Incendio con 1.000 y 10.000 intentos para cada tipo de evidencia. En todas las ejecuciones se utilizó la semilla 7.

Evidencia	Intentos	Aceptadas	P estimada	P exacta	Error absoluto
Ninguna	1.000	1.000	0.056000	0.065160	0.009160
Ninguna	10.000	10.000	0.063400	0.065160	0.001760
Alarma	1.000	191	0.277487	0.329517	0.052030
Alarma	10.000	1.841	0.315589	0.329517	0.013928
Rara	1.000	0	—	0.260778	—
Rara	10.000	11	0.090909	0.260778	0.169869

Muestreo a priori: sin evidencia se aceptaron todas las muestras. El error absoluto disminuyó de 0.009160 a 0.001760 al pasar de 1.000 a 10.000 intentos, acercándose al valor exacto de 0.065160.

Rechazo con alarma: se aceptaron 191 muestras de 1.000 intentos y 1.841 de 10.000. El error pasó de 0.052030 a 0.013928. En estas ejecuciones, el mayor número de muestras aceptadas permitió una mejor aproximación a la referencia exacta de 0.329517.

Rechazo con evidencia rara: la evidencia fue Tormenta=1, Falla=1 y Alarma=1. Con 1.000 intentos no se aceptó ninguna muestra y no hubo estimación. Con 10.000 intentos se aceptaron solo 11; la probabilidad estimada fue 0.090909 frente a 0.260778 exacta, con error 0.169869.

Conclusión: al usar muestreo a priori sin evidencia se aprovechan todas las muestras. En el muestreo por rechazo, cuando la evidencia es poco frecuente se descarta la mayoría de los intentos y la aproximación puede ser inestable. Aumentar el número de intentos no garantiza menor error en una ejecución particular.

Punto 4: MDP e iteración de valores

4a. Identificación de los elementos del MDP

El escenario cuadricula representa el movimiento de un dron en un entorno con incertidumbre.

Estados: las posiciones transitables de la cuadrícula. Hay 11 estados, incluyendo los dos terminales.

Acciones: Norte (N), Este (E), Sur (S) y Oeste (W).

Transiciones: con ruido de 0.20, la acción seleccionada tiene probabilidad de 0.80 y cada desviación perpendicular tiene probabilidad de 0.10. Si el dron encuentra un muro o borde, permanece en su posición.

Recompensas: el movimiento normal tiene una recompensa de -0.04. Llegar al objetivo favorable proporciona +1 y llegar al terminal desfavorable proporciona -1.

Estados terminales: G (objetivo favorable) y X (pérdida del dron).

Descuento: $\gamma = 0.90$.

Se cumple la propiedad de Markov porque la posición actual y la acción seleccionada son suficientes para determinar las probabilidades del siguiente estado. No es necesario conocer los movimientos anteriores.

4d. Comprobación de la iteración de valores

Escenario control

Se ejecutó el algoritmo con ruido 0, recompensa por movimiento -0.04 y descuento 0.90. El algoritmo convergió en 2 barridos, obteniendo V(inicio) = 1.000000. La mejor acción fue Este, con Q = 1.000000.

Escenario cuadricula

Se ejecutó el algoritmo con ruido 0.20, recompensa por movimiento -0.04 y descuento 0.90. Se alcanzó la convergencia después de 26 barridos, obteniendo V(inicio) = 0.373852.

En los primeros tres barridos, los valores del estado inicial fueron -0.040000, -0.076000 y -0.108400. Posteriormente, los valores aumentaron al considerar las recompensas futuras hasta estabilizarse aproximadamente en 0.373852.

En el estado inicial se obtuvieron los siguientes valores de acción:

Norte: 0.373852

Este: 0.272666

Sur: 0.292216

Oeste: 0.306671

La mejor acción fue Norte, al presentar el mayor valor esperado.

Criterio de parada

El algoritmo calcula el cambio máximo absoluto entre los valores de dos barridos consecutivos. Cuando este cambio es menor que la tolerancia de 0.00000001, se considera que ha convergido.

En el barrido 26, el cambio máximo fue aproximadamente 0.00000000691, por lo que se cumplió el criterio de convergencia.

Conclusión

La iteración de valores permite considerar no solo la recompensa inmediata, sino también las posibles recompensas futuras. Los valores se actualizan progresivamente hasta estabilizarse y permiten identificar la mejor acción para cada estado.

Punto 5: Extracción y análisis de políticas

A.

Para cada estado se evalúan las acciones disponibles mediante action_value. Esta función combina todas las transiciones posibles, su probabilidad, la recompensa de llegada y el valor futuro:

$Q(s,a) = \sum s' T(s,a,s') \, [R(s,a,s') + \gamma \, V(s')] \quad Q(s,a) = \sum s' T(s,a,s') \, [R(s,a,s') + \gamma V(s')]$

extract_policy selecciona la acción con mayor Q. El modelo entrega las acciones en el orden N, E, S, W y max conserva la primera cuando sus valores son iguales. Si no hay acciones, devuelve None. Esto corresponde a los terminales. El diccionario de valores se consulta sin modificarlo.

```
def extract_policy(mdp, values):
    policy = {}
    for state in mdp.states:
        policy[state] = max(
            mdp.actions(state),
            key=lambda action: action_value(mdp, state, action, values),
            default=None,
        )
    return policy
```

Se usa el valor completo de la acción, no únicamente el de la celda vecina. Tampoco se redondean los valores Q antes de compararlos: dos números cercanos no se convierten artificialmente en un empate.

B.

Se comparó noise=0 con noise=0.3, manteniendo living_reward=-0.04 y discount=0.95. G entrega +2 y X entrega -5. Con ruido 0.3, el movimiento previsto ocurre con probabilidad 0.7 y cada desvío perpendicular con 0.15.

Ruido	V del inicio	Acción inicial	Barridos
0	1.366587	E	9
0.3	0.711171	N	93

Acción en S	Q con ruido 0	Q con ruido 0.3
N	1.155344	0.711171
E	1.366587	0.665141
S	1.155344	0.390150
W	1.258257	0.592537

En S=(0,2), la decisión cambia de E a N. Sin viento, avanzar al este conduce directamente a la descarga por la fila cercana a X. Con viento, esa fila expone al dron a desvíos hacia las celdas de pérdida. Subir permite transitar por una fila más alejada del peligro: Q(N)=0.711171 supera Q(E)=0.665141. El valor inicial disminuye de 1.366587 a 0.711171.

Políticas completas

Las letras indican la acción. S marca el inicio, G y X son terminales sin acción. Se muestran todos los estados, incluidos aquellos que una trayectoria particular puede no visitar.

Ruido 0

y / x	0	1	2	3	4	5	6
0	E	E	E	E	E	E	S
1	E	E	E	E	E	E	S
2	S:E	E	E	E	E	E	G
3	N	X	X	X	X	X	N

Ruido 0.3

y / x	0	1	2	3	4	5	6
0	E	E	E	E	E	E	S
1	E	E	E	E	E	E	S
2	S:N	N	N	N	N	N	G
3	W	X	X	X	X	X	E

Cambian 8 decisiones: (0,2), (1,2), (2,2), (3,2), (4,2), (5,2), (0,3) y (6,3). Las decisiones terminales permanecen en None.

C.

En zona_riesgo se comparó living_reward=-0.04 con -0.30, manteniendo noise=0.1 y discount=0.95. La penalización adicional de las celdas R es -0.40 y G entrega +2. Por tanto, entrar en R cuesta -0.44 o -0.70, respectivamente. Permanecer en R por un rebote también recibe esta penalización.

Recompensa por paso	V del inicio	Acción inicial	Barridos
-0.04	1.003639	N	28
-0.30	-0.715505	E	27

El inicio cambia de N a E. Con -0.04, Q(N)=Q(S)=1.003639 supera Q(E)=0.996224, se conserva N por el desempate. Con -0.30, Q(E)=-0.715505 supera Q(N)=Q(S)=-0.726344. El costo acumulado reduce el valor inicial y modifica la elección.

En la celda R de (3,1)	Paso -0.04	Paso -0.30
V(3,1)	1.348528	0.636491
Q(N)	1.348528	0.306580
Q(E)	1.284367	0.636491
Acción elegida	N	E

En (3,1), con el costo menor conviene salir hacia el norte. Con el costo mayor conviene avanzar al este, aunque la siguiente celda también es R. Reducir los movimientos pendientes compensa la penalización en este estado. Cambian dos decisiones en total: (0,1) y (3,1). Esto no significa que la política pase a atravesar toda la franja de riesgo: en (1,1) sigue eligiendo N.

Esta comparación es independiente: se restauró living_reward=-0.04, se mantuvo noise=0.1 y se cambió únicamente discount de 0.95 a 0.50.

Descuento	V del inicio	V en (1,1)	Acción en (1,1)
0.95	1.003639	1.089252	N
0.50	-0.073433	-0.075548	W

Con descuento 0.50, las recompensas lejanas pesan menos. En (1,1), Q(W)=-0.075548 es mayor que Q(N)=-0.086098. Ir al oeste evita el desvío inmediato hacia la celda R de (2,1) que puede ocurrir al intentar ir al norte. Con 0.95 se prioriza el avance hacia la recompensa futura y se elige N. Solo cambia esta decisión, en el inicio se mantiene N. La ejecución con 0.50 converge en 19 barridos, frente a 28 con 0.95.

Políticas completas de zona riesgo

R identifica una celda con penalización adicional. En cada comparación se cambia solo el parámetro indicado respecto del caso base. Las tablas permiten comprobar los cambios en estados que podrían quedar fuera de una trayectoria simulada.

Parámetros originales

y / x	0	1	2	3	4	5	6
0	E	E	E	E	E	E	S
1	S:N	N	R:N	R:N	R:E	E	G
2	E	E	E	E	E	E	N

Mayor costo por movimiento

y / x	0	1	2	3	4	5	6
0	E	E	E	E	E	E	S
1	S:E	N	R:N	R:E	R:E	E	G
2	E	E	E	E	E	E	N

Menor descuento

y / x	0	1	2	3	4	5	6
0	E	E	E	E	E	E	S
1	S:N	W	R:N	R:N	R:E	E	G
2	E	E	E	E	E	E	N

Punto 6: Reflexión sobre el trabajo realizado

E.

El ruido incrementa la exposición a resultados no deseados. En atajo, pasar de 0 a 0.3 cambia la decisión inicial de E a N y reduce su valor esperado. Un costo por movimiento más negativo vuelve más costosa la demora: en zona_riesgo, pasar de -0.04 a -0.30 cambia la acción en (3,1) de N a E. Al reducir el descuento de 0.95 a 0.50, pesa menos la descarga futura y se evita más la penalización inmediata. En (1,1) se cambia de N a W.

Una política es una regla que asigna una acción a cada estado. Una ruta es una secuencia concreta de posiciones. Con viento, ejecutar la misma política puede producir rutas diferentes, porque el siguiente estado es aleatorio. Una trayectoria exitosa no demuestra que una política sea óptima, ni su retorno equivale al valor esperado del inicio.

Por ejemplo, con ruido 0.3 y semilla 7, la trayectoria de atajo alcanza G en 8 movimientos y obtiene retorno 1.155344, mientras V(S)=0.711171. La diferencia es compatible con que una

realización resulte mejor que el promedio esperado. La semilla afecta la trayectoria ilustrativa. La iteración de valores y la extracción de política son deterministas.